

SECOND CLASSWORK – DATA MINING INTRODUCTION

Santo Lo Bianco 1000061604

Il dataset analizzato, formato in formato Excel, contiene informazioni sui bambini che vengono divisi in tre categorie:

- **ASD** -> bambini con diagnosi di autismo;
- **GDD** -> bambini con ritardo globale dello sviluppo;
- **Controlli** -> bambini con sviluppo tipico.

Ogni paziente è descritto da diverse caratteristiche misurate attraverso scale cliniche con valori compresi tra 0, 1 e 2.

Alcune variabili al fine della classificazione sono state rimosse. Le variabili rimosse sono le seguenti:

- **Età cronologica (mesi);**
- **Scala B** -> score totale della scala 'comunicazione e linguaggio';
- **Scala D** -> score totale della scala 'personale, sociale ed emotiva';
- **TOT.** -> score totale per tutte le scale;
- **Score di rischio** -> etichetta derivata dal punteggio complessivo;

Inoltre, per evitare che i valori di default (values = 0) potessero introdurre rumore nei dati, sono stati rimossi i bambini con '**Età equivalente**' inferiore ai 12 mesi.

L'età equivalente è stata mantenuta, infatti rappresenta una misura sintetica e significativa dello sviluppo del bambino. Essa si riferisce all'età non reale ma quella dimostrata o calcolata attraverso i punteggi ottenuti nelle scale di valutazione considerate.


Per quanto riguarda la variabile '**Sesso**' è stata mantenuta in quanto non è stato indicato diversamente nella consegna. Dato che la variabile è categorica, è stata mappata in forma numerica prima dell'applicazione della PCA.

Terminata la fase di pre-processing sui tre fogli, si è stabilito di concatenare in un unico dataframe i tre dataset, così da consentire l'**applicazione della PCA** su tutti i dati in modo compatto e facilitarne la visualizzazione comparativa tra le classi.

Le **prime due componenti principali selezionate** spiegano complessivamente circa il **34% della varianza totale** del dataset. Ciò indica che una parte significativa è anche distribuita anche nelle componenti successive.

Explained variance ratio: [0.23758323 0.10392344]

Il grafico che segue è la rappresentazione dei dati ridotti mediante PCA(2 dimensioni).



L'analisi PCA in 2D mostra una **separazione parziale** tra le tre classi.

I bambini con sviluppo tipico sono concentrati in una regione compatta, mentre i soggetti ASD e GDD presentano maggiore dispersione (anche se GDD in minore quantità).

Si osserva una **sovrapposizione considerevole tra le classi GDD e Controlli**, indicando una separazione non completamente lineare.

La PCA in questa fase è stata utilizzata esclusivamente a scopo esplorativo e di visualizzazione, mentre la fase successiva è stata dedicata alla costruzione di modelli di classificazione.

I modelli richiesti per la classificazione sono:

- **Alberi di decisione** -> modello di base per la classificazione;
- **Random Forest** -> migliora le capacità attraverso insieme di alberi;
- **K-Nearest Neighbors** -> basato sulla distanza tra le osservazioni;
- **SVC(Support Vector Classifier)** -> utilizzato per individuare dei confini decisionali;

Prima di costruire i già citati modelli di classificazione si è diviso il dataset in training set e test set. Solo dopo questa divisione si è creata la pipeline che:

- Fa scaling dei dati tramite StandardScaler;
- Addestra il classificatore sul training set;
- Ottimizza gli iper-parametri principali dei modelli attraverso GridSearchCV.

Gli iper-parametri variano per ogni modello, dato che sono influenzati dalla propria natura.

Albero di decisione	Profondità albero: "clf__max_depth": [None, 5, 10, 20] Numero campioni richiesto per dividere un nodo interno: "clf__min_samples_split": [2, 5, 10]
Random Forest	Numero di alberi presenti: "clf__n_estimators" : [50,100] Profondità massima: "clf__max_depth" : [None, 10, 20]
SVC	Parametro di regolarizzazione: "clf__C" : [0.1, 1, 10] Confine lineare o non lineare: "clf__kernel" : ["linear", "rbf"]
KNN	Numero vicini considerati: "clf__n_neighbors" : [3, 5, 7], Contributo dei vicini: "clf__weights": ["uniform", "distance"]

I modelli sono stati valutati sul test set utilizzando l'**accuracy** come metrica principale.

Dall'analisi dei risultati emerge che gli Alberi di decisione hanno ottenuto la maggiore accuratezza sul test set (62.5%), seguito da SVC (60%), Random Forest (57.5%) e K-NN (55%). In generale, la classificazione risulta difficile per la distinzione tra GDD e Controlli, come evidenziato anche nella PCA, mentre i casi ASD più marcati sono stati più facilmente identificati.

Di seguito sono riportati i risultati, compresi i parametri ottimizzati attraverso GridSearchCV.

Albero di decisione	'clf__max_depth': None , 'clf__min_samples_split': 10
	Test accuracy: 0.625
Random Forest	'clf__max_depth': None 'clf__n_estimators': 50
	Test accuracy: 0.575
SVC	'clf__C': 1 'clf__kernel': 'rbf'
	Test accuracy: 0.6
KNN	'clf__n_neighbors': 5 'clf__weights': 'uniform'
	Test accuracy: 0.55

Per migliorare le prestazioni dei modelli di classificazione e ridurre il rischio di overfitting o di errori su casi difficili, sono stati applicati i concetti di **Bagging** e **Boosting**, ossia due tecniche che permettono rispettivamente di utilizzare modelli in parallelo o in modo sequenziale.

In particolare abbiamo applicato il bagging all'Albero di decisione, SVC e KNN e invece il boosting solo all'albero di decisione. I risultati sono i seguenti:

- Bagging Decision Tree accuracy: **0.6**
- Boosting Decision Tree accuracy: **0.55**
- Bagging K-NN accuracy: **0.575**
- Bagging SVC accuracy: **0.575**

L'uso di Bagging e Boosting non ha portato a un miglioramento dell'accuracy rispetto ai modelli base; in alcuni casi, le prestazioni sono leggermente peggiori. Tuttavia, queste tecniche hanno permesso di stabilizzare le predizioni e confermare l'eterogeneità e la sovrapposizione delle classi osservata nella PCA.