

Autoencoder su profili di espressione per il calcolo delle correlazioni tra geni

Studente: Santo Lo Bianco

email: lobiancosanto23@gmail.com

Punteggio massimo: 12

Obiettivo: Data una matrice di espressione, le cui righe contengono i geni, mentre le colonne i pazienti, calcolare la misura di correlazione per ogni coppia di geni presenti nella matrice. L'approccio deve essere ripetuto considerando sia una trasformazione non lineare dello spazio per mezzo di autoencoder, e sia una trasformazione lineare dello spazio con impiego della tecnica PCA.

Da dove scaricare i dati: essi possono essere scaricati da <https://xenabrowser.net/datapages>. Seleziona i seguenti cancri:

- [GDC TCGA Colon Cancer \(COAD\)](#)
- [GDC TCGA Breast Cancer \(BRCA\)](#)
- [GDC TCGA Lung Adenocarcinoma \(LUAD\)](#)
- [GDC TCGA Ovarian Cancer \(OV\)](#)
- [GDC TCGA Pancreatic Cancer \(PAAD\)](#)
- [GDC TCGA Prostate Cancer \(PRAD\)](#)

Cliccando nel link, recati alla sezione gene expression RNASeq, clicca su STAR-FPKM e scarica la matrice per ogni tumore.

Per ogni matrice sostituire il codice ensemble dei geni nel corrispettivo nome. L'url del database è: <https://www.ensembl.org/index.html>. Inoltre la specie da considerare è Homo Sapiens. Ricorda che il codice dei geni è spesso seguito da .numero. Elimina il .numero prima di effettuare la ricerca e sostituzione.

Cosa fare: i task da eseguire per ogni matrice sono essenzialmente 3.

Task 1: Calcolare il valore di correlazione per ogni coppia di geni sfruttando la matrice reale.

Task 2: Calcolare il valore di correlazione per ogni coppia di geni sfruttando il vettore compresso in uscita dall'encoder dell'autoencoder creato.

Task 3: Calcolare il valore di correlazione per ogni coppia di geni sfruttando il la PCA.